



UNIVERSITÉ IBN ZOHR
FACULTÉ DES SCIENCES D'AGADIR
CENTRE D'EXCELLENCE

Licence d'Excellence en
Intelligence Artificielle et Analytique des Données

PRÉDICTION DU CHURN CLIENT

Analyse exploratoire des données et
modélisation prédictive par Machine Learning

Présenté par

Asma Ouchen

Encadrement académique

Anass Garbaz

Encadrement en entreprise

Mohamed Boukrani

Année universitaire 2025–2026

Remerciements

Je tiens tout d'abord à exprimer ma profonde gratitude à la **Faculté des Sciences d'Agadir** et au **Centre d'Excellence** pour la qualité de la formation dispensée ainsi que pour l'environnement académique qui m'a permis de développer mes connaissances et mes compétences dans le domaine de l'Intelligence Artificielle et de l'Analytique des Données.

Je souhaite également adresser mes sincères remerciements à **Orange Digital Center Agadir** pour l'accueil, les conditions de travail et l'environnement professionnel qui m'ont permis de mettre en pratique les connaissances acquises au cours de ma formation et d'enrichir mon expérience dans le domaine de la Data Science.

J'adresse mes sincères remerciements à mon **encadrant académique, Anass Garbaz**, pour son accompagnement, ses conseils, sa disponibilité et son suivi tout au long de la réalisation de ce projet. Ses orientations ont été précieuses pour structurer et mener à bien ce travail.

Je tiens également à remercier mon **encadrant en entreprise, Mohamed Boukrani**, pour son accueil, son accompagnement professionnel, ses conseils et ses orientations tout au long de cette expérience.

Je remercie également l'ensemble des enseignants de la **Faculté des Sciences d'Agadir** pour leurs enseignements, leurs conseils et les connaissances transmises tout au long de mon parcours académique.

Enfin, j'adresse mes remerciements à toutes les personnes qui ont contribué, directement ou indirectement, à la réalisation de ce projet et qui m'ont apporté leur soutien, leurs conseils et leurs encouragements.

Asma Ouchen

Résumé

La fidélisation des clients constitue un enjeu majeur pour les entreprises de télécommunications. Dans ce contexte, la prédiction du départ des clients, communément appelée *churn*, permet d'identifier les profils susceptibles de résilier leur contrat et d'apporter ainsi une aide à la mise en place d'actions de fidélisation adaptées.

Ce projet porte sur l'analyse et la prédiction du churn client à partir d'un jeu de données contenant différentes informations relatives aux clients, à leurs services, à leur ancienneté, à leur satisfaction et à leurs caractéristiques financières.

Une analyse exploratoire des données a ensuite été réalisée afin d'étudier la distribution des variables, d'identifier les caractéristiques associées au départ des clients et d'analyser les relations entre les différentes variables.

Plusieurs algorithmes de Machine Learning ont ensuite été entraînés et comparés, notamment la régression logistique, l'arbre de décision, la forêt aléatoire, le Gradient Boosting et les k plus proches voisins. Les modèles ont été évalués à l'aide de différentes métriques de classification, notamment l'accuracy, la précision, le rappel et le score F1.

Une phase d'optimisation des modèles a également été réalisée à l'aide de la validation croisée et de la recherche par grille (*GridSearchCV*), afin d'identifier les hyperparamètres offrant les meilleures performances.

Enfin, le modèle retenu a été intégré dans une application interactive développée avec **Streamlit**. Cette application permet à un utilisateur de renseigner les caractéristiques d'un client et d'obtenir une prédiction de son risque de churn. Cette étape permet ainsi de transformer le modèle de Machine Learning en un outil simple et interactif pouvant faciliter l'utilisation des résultats de l'analyse.

Mots-clés : Churn client, Analyse de données, Machine Learning, Classification, Prétraitement, Gradient Boosting, Régression Logistique, Optimisation, Prédiction, Streamlit.

Table des matières

Remerciements	1
Résumé	2
1 Introduction	6
1.1 Contexte général	6
1.2 Problématique	6
1.3 Objectifs du projet	7
1.4 Méthodologie générale	7
2 Compréhension et Nettoyage des données	9
2.1 Présentation du jeu de données	9
2.2 Dimensions et structure du dataset	9
2.3 Description des variables	9
2.3.1 Variables liées aux caractéristiques des clients	10
2.3.2 Variables géographiques	10
2.3.3 Variables relatives aux services	10
2.3.4 Variables contractuelles et financières	10
2.3.5 Variables liées au churn	11
2.4 Types des variables	11
2.5 Nettoyage des Données :	11
2.6 Vérification et traitement des doublons	12
2.7 Traitement des valeurs manquantes	12
2.8 Nettoyage des variables catégorielles	13
2.9 Identification des variables constantes	13
2.10 Suppression des variables inutiles	13
2.11 Vérification des valeurs incohérentes	14
2.11.1 Âge des clients	14
2.11.2 Ancienneté des clients	14
2.11.3 Variables financières	15
2.12 Détection des valeurs atypiques	15

2.13	Résultat final du nettoyage	16
2.14	Conclusion	17
3	Analyse exploratoire des données	18
3.1	Analyse univariée des variables clés	18
3.1.1	Distribution de la variable cible	18
3.1.2	Statistiques descriptives	19
3.1.3	Lecture des principales variables	19
3.2	Analyse des variables catégorielles	20
3.3	Analyse bivariée : facteurs influençant le churn	21
3.4	Variables directement liées au churn	22
3.5	Analyse des corrélations entre variables numériques	23
3.5.1	Corrélations très fortes	23
3.5.2	Corrélations fortes	23
3.5.3	Corrélation négative importante	24
3.5.4	Implications pour la modélisation	24
4	Démarche et méthodologie de modélisation	25
4.1	Introduction	25
4.2	Préparation des données	25
4.2.1	Définition de la variable cible	25
4.2.2	Prévention de la fuite de données	25
4.2.3	Séparation des données	26
4.2.4	Encodage et standardisation	26
4.3	Algorithmes utilisés	26
4.3.1	Régression Logistique	26
4.3.2	Arbre de Décision	27
4.3.3	Random Forest	27
4.3.4	Gradient Boosting	28
4.3.5	K-Nearest Neighbors (KNN)	28
4.4	Démarche de modélisation	29
4.4.1	Optimisation des hyperparamètres	29
4.4.2	Validation croisée	29
4.4.3	Évaluation sur l'ensemble de test	29
4.4.4	Sélection du meilleur modèle	30
4.4.5	Validation croisée	30
4.4.6	Évaluation finale	30
4.4.7	Comparaison des deux configurations	31

4.4.8	Sélection du modèle final	31
5	Évaluation et résultats	33
5.1	Introduction	33
5.2	Résultats avec SatisfactionScore	33
5.2.1	Optimisation	33
5.2.2	Performances finales	35
5.3	Évaluation du modèle final	35
5.3.1	Matrice de confusion	35
5.3.2	Métriques d'évaluation	36
5.3.3	Importance des variables	37
5.4	Résultats sans SatisfactionScore	38
5.4.1	Optimisation	38
5.4.2	Performances finales	39
5.4.3	Matrice de confusion	39
5.4.4	Métriques d'évaluation	40
5.4.5	Importance des variables	41
5.5	Comparaison des deux configurations	41
5.6	Conclusion	42
6	Mise en application avec Streamlit	43
6.1	Sauvegarde du modèle	43
6.2	Sauvegarde des éléments de prétraitement	43
6.3	Application Streamlit	43
6.4	Conclusion	44
	Conclusion générale	45

Chapitre 1

Introduction

1.1 Contexte général

Dans un environnement de plus en plus concurrentiel, les entreprises de télécommunications doivent accorder une importance particulière à la fidélisation de leurs clients. Le départ d'un client, également appelé *churn*, peut représenter une perte importante pour l'entreprise et nécessite la mise en place de stratégies permettant d'identifier les facteurs associés à ces départs.

L'exploitation des données clients constitue ainsi un levier important pour mieux comprendre les comportements des clients et anticiper les situations susceptibles de conduire à une résiliation.

Les techniques d'analyse de données et de Machine Learning permettent notamment d'exploiter les informations historiques disponibles afin de construire des modèles capables de prédire la probabilité de départ d'un client.

Dans ce contexte, ce projet vise à mettre en place une démarche complète allant de l'analyse des données jusqu'à la mise en application du modèle prédictif dans une interface interactive développée avec **Streamlit**.

1.2 Problématique

La problématique principale de ce projet consiste à déterminer dans quelle mesure les caractéristiques des clients, leurs services, leur ancienneté, leur niveau de satisfaction ainsi que leurs informations financières peuvent être utilisées pour prédire leur départ.

La question centrale peut ainsi être formulée comme suit :

Comment exploiter les données disponibles sur les clients afin d'identifier les facteurs associés au churn et de construire un modèle de Machine Learning capable de prédire efficacement les clients susceptibles de quitter l'entreprise ?

Au-delà de la construction du modèle, l'objectif est également de rendre les résultats accessibles à travers une application interactive permettant d'utiliser le modèle pour effectuer des prédictions sur de nouveaux profils clients.

1.3 Objectifs du projet

L'objectif principal de ce projet est de développer une démarche complète d'analyse et de prédiction du churn client à partir des données disponibles, puis de mettre le modèle obtenu à disposition dans une application interactive.

Les objectifs spécifiques sont les suivants :

- Comprendre la structure et les caractéristiques du jeu de données.
- Effectuer le nettoyage et le prétraitement des données.
- Réaliser une analyse exploratoire afin d'identifier les principales caractéristiques associées au churn.
- Préparer les données pour la modélisation en Machine Learning.
- Entraîner et comparer plusieurs algorithmes de classification.
- Évaluer les performances des différents modèles à l'aide de plusieurs métriques.
- Optimiser les hyperparamètres des modèles afin d'améliorer leurs performances.
- Sélectionner le modèle le plus performant pour la prédiction du churn.
- Interpréter les résultats et identifier les variables les plus importantes dans la prédiction du churn.
- Sauvegarder le modèle final et les éléments nécessaires à son utilisation.
- Développer une application interactive avec **Streamlit** permettant d'utiliser le modèle pour effectuer des prédictions de churn.

1.4 Méthodologie générale

La démarche adoptée dans ce projet suit plusieurs étapes successives, allant de la compréhension du problème jusqu'à la mise en application du modèle prédictif.

Dans un premier temps, le jeu de données est étudié afin de comprendre sa structure, ses différentes variables et sa qualité. Une phase de nettoyage est ensuite réalisée afin de traiter les valeurs manquantes, les éventuelles incohérences ainsi que les variables jugées inutiles pour l'objectif de prédiction.

Une analyse exploratoire des données est ensuite menée afin d'étudier les distributions des variables, les relations entre celles-ci et les principales caractéristiques associées au churn. Cette étape permet également de mieux comprendre le comportement des clients et d'orienter la sélection des variables utilisées pour la modélisation.

Après cette étape, les données sont préparées pour le *Machine Learning*. Les variables catégorielles et numériques sont transformées selon les besoins des algorithmes, puis les données sont séparées en ensembles d'entraînement et de test.

Plusieurs modèles de classification sont ensuite entraînés et comparés, notamment la régression logistique, l'arbre de décision, la forêt aléatoire, le Gradient Boosting et les k plus proches voisins. Leurs performances sont évaluées à l'aide de plusieurs métriques, notamment l'accuracy, la précision, le rappel et le F1-score.

Une phase d'optimisation est ensuite réalisée à l'aide de la validation croisée et de la recherche d'hyperparamètres (*GridSearchCV*) afin d'obtenir une configuration performante du modèle retenu.

Enfin, le modèle final est sauvegardé et intégré dans une application interactive développée

avec **Streamlit**. L'application permet à l'utilisateur de renseigner les caractéristiques d'un client et d'obtenir une prédiction de son risque de churn. Cette dernière étape permet ainsi de transformer le modèle développé en un outil simple et exploitable pour la prédiction de nouveaux clients.

Chapitre 2

Compréhension et Nettoyage des données

2.1 Présentation du jeu de données

Le jeu de données utilisé dans ce projet est un ensemble de données relatif aux clients d'une entreprise de télécommunications. Il contient différentes informations permettant de caractériser les clients, leurs services, leur ancienneté, leurs habitudes de consommation, leur satisfaction ainsi que leur comportement vis-à-vis de l'entreprise.

L'objectif de cette première étape est de comprendre la structure du jeu de données "TelcoCustomerChurn.csv" avant d'effectuer les opérations de nettoyage et de prétraitement.

2.2 Dimensions et structure du dataset

L'exploration initiale montre que le jeu de données contient **7 043 clients** et **50 variables**.

TABLE 2.1 – Dimensions du jeu de données

Caractéristique	Valeur
Nombre de clients	7 043
Nombre de variables	50

Chaque ligne correspond à un client tandis que chaque colonne représente une caractéristique associée à ce client.

La consultation des premières lignes du dataset permet de constater la diversité des informations disponibles.

2.3 Description des variables

Les 50 variables peuvent être regroupées selon plusieurs catégories.

2.3.1 Variables liées aux caractéristiques des clients

Cette catégorie comprend notamment :

- `Gender` : sexe du client ;
- `Age` : âge du client ;
- `Under30` : indication permettant d'identifier les clients de moins de 30 ans ;
- `SeniorCitizen` : indication concernant le statut de senior ;
- `Married` : statut marital ;
- `Dependents` : présence de personnes à charge ;
- `NumberOfDependents` : nombre de personnes à charge.

2.3.2 Variables géographiques

Les informations géographiques comprennent notamment :

- `Country` ;
- `State` ;
- `City` ;
- `ZipCode` ;
- `Latitude` ;
- `Longitude` ;
- `Population`.

2.3.3 Variables relatives aux services

Le dataset contient également plusieurs variables décrivant les services utilisés par les clients :

- `PhoneService` ;
- `MultipleLines` ;
- `InternetService` ;
- `InternetType` ;
- `OnlineSecurity` ;
- `OnlineBackup` ;
- `DeviceProtectionPlan` ;
- `PremiumTechSupport` ;
- `StreamingTV` ;
- `StreamingMovies` ;
- `StreamingMusic` ;
- `UnlimitedData`.

2.3.4 Variables contractuelles et financières

Plusieurs variables permettent de caractériser les conditions contractuelles et financières des clients :

- Contract;
- PaperlessBilling;
- PaymentMethod;
- MonthlyCharge;
- TotalCharges;
- TotalRefunds;
- TotalExtraDataCharges;
- TotalLongDistanceCharges;
- TotalRevenue.

2.3.5 Variables liées au churn

Enfin, plusieurs variables sont directement associées au départ des clients :

- CustomerStatus;
- ChurnLabel;
- ChurnScore;
- CLTV;
- ChurnCategory;
- ChurnReason.

La variable ChurnLabel constitue la **variable cible** du problème de classification. Elle indique si le client a quitté l'entreprise ou non.

2.4 Types des variables

L'analyse des types de données montre que le dataset contient **31 variables de type catégoriel**, **11 variables entières** et **8 variables continues**.

TABLE 2.2 – Répartition des types de variables

Type	Nombre de variables
Variables catégorielles (object)	31
Variables entières (int64)	11
Variables continues (float64)	8
Total	50

Cette diversité de types de données nécessite l'utilisation de techniques de prétraitement adaptées avant l'entraînement des modèles de Machine Learning.

2.5 Nettoyage des Données :

Après avoir effectué la compréhension générale du jeu de données, une étape de nettoyage est nécessaire afin de garantir la qualité des données utilisées pour les analyses et la modélisation.

Cette étape consiste à vérifier l'existence de doublons, à traiter les valeurs manquantes, à nettoyer les variables catégorielles, à identifier les colonnes inutiles ou constantes, à rechercher les valeurs incohérentes et enfin à détecter les valeurs atypiques (*outliers*).

L'objectif est d'obtenir un jeu de données propre et cohérent, tout en conservant les informations pertinentes pour les étapes d'analyse exploratoire et de Machine Learning.

2.6 Vérification et traitement des doublons

La première étape du nettoyage consiste à vérifier l'existence d'observations dupliquées dans le jeu de données.

Le nombre de doublons détectés avant le nettoyage est de **0**.

Une suppression des doublons a néanmoins été appliquée afin de garantir l'unicité des observations.

Après cette opération, le nombre de doublons reste égal à **0**.

TABLE 2.3 – Vérification des doublons

Indicateur	Résultat
Doublons avant traitement	0
Doublons après traitement	0

L'absence de doublons indique que chaque observation du dataset correspond à une ligne unique.

2.7 Traitement des valeurs manquantes

L'analyse réalisée lors de la compréhension des données avait permis d'identifier plusieurs variables contenant des valeurs manquantes.

Les principales variables concernées sont **Offer**, **InternetType**, **ChurnCategory** et **ChurnReason**.

TABLE 2.4 – Traitement des valeurs manquantes

Variable	Valeurs manquantes	Traitement
Offer	3 877	No Offer
InternetType	1 526	No Internet
ChurnCategory	5 174	Not Churned
ChurnReason	5 174	Not Churned

Pour la variable **Offer**, les valeurs manquantes ont été remplacées par la modalité *No Offer*. Cette valeur permet d'indiquer explicitement qu'aucune offre n'est renseignée pour le client.

De même, les valeurs manquantes de **InternetType** ont été remplacées par *No Internet*. Cette modalité permet de distinguer l'absence d'information d'un type d'accès Internet particulier.

Concernant les variables **ChurnCategory** et **ChurnReason**, les valeurs manquantes correspondent aux clients n'ayant pas quitté l'entreprise. Elles ont donc été remplacées

respectivement par *Not Churned*.

Après ce traitement, aucune valeur manquante ne subsiste dans le dataset.

TABLE 2.5 – Valeurs manquantes avant et après traitement

Indicateur	Avant	Après
Nombre total de valeurs manquantes	15 751	0

2.8 Nettoyage des variables catégorielles

Les variables catégorielles ont également été examinées afin de détecter la présence éventuelle d'espaces inutiles au début ou à la fin des valeurs.

La vérification effectuée après cette opération n'a détecté aucun espace inutile dans les valeurs des variables catégorielles.

Cette étape permet d'éviter la création de catégories artificielles qui pourraient être considérées comme différentes par les algorithmes de Machine Learning.

2.9 Identification des variables constantes

Une variable constante est une variable qui possède une seule modalité dans l'ensemble du dataset. Une telle variable n'apporte aucune information discriminante pour l'analyse ou la modélisation.

L'analyse a permis d'identifier trois variables constantes :

- **Country** : toutes les observations correspondent aux États-Unis ;
- **State** : toutes les observations correspondent à la Californie ;
- **Quarter** : toutes les observations appartiennent au troisième trimestre (*Q3*).

Ces variables ont donc été supprimées du dataset.

2.10 Suppression des variables inutiles

Après l'analyse de la structure du jeu de données, certaines variables ont été supprimées car elles ne présentent pas d'intérêt pour l'objectif de prédiction du churn.

Tout d'abord, la variable **CustomerID** constitue un identifiant unique attribué à chaque client. Elle ne représente pas une caractéristique descriptive ou comportementale du client et n'apporte donc pas d'information pertinente pour la modélisation.

Les variables **Country**, **State** et **Quarter** ont également été supprimées car elles sont constantes dans l'ensemble du jeu de données. Elles ne permettent donc pas de distinguer les différents clients.

Par ailleurs, les variables géographiques **City**, **ZipCode**, **Latitude**, **Longitude** et **Population** ont été supprimées. Bien qu'elles puissent contenir des informations sur la localisation des clients, elles ne sont pas directement nécessaires pour répondre à l'objectif principal de cette étude, qui consiste à prédire le churn à partir des caractéristiques des clients, des services utilisés, de l'ancienneté, de la satisfaction et des informations financières. Leur

suppression permet également de réduire la dimension du jeu de données et de concentrer l'analyse sur les variables les plus pertinentes pour la problématique étudiée.

Au total, les variables supprimées à cette étape sont :

- CustomerID;
- Country;
- State;
- Quarter;
- City;
- ZipCode;
- Latitude;
- Longitude;
- Population.

Le jeu de données initial contenait **50 variables**. Après la suppression de ces **9 variables**, le nombre de variables est ramené à **41**, tandis que le nombre de clients reste inchangé à **7 043**.

TABLE 2.6 – Dimensions du dataset après suppression des variables inutiles

Caractéristique	Valeur
Nombre de clients	7 043
Nombre de variables avant nettoyage	50
Nombre de variables supprimées	9
Nombre de variables après nettoyage	41

2.11 Vérification des valeurs incohérentes

Une vérification des valeurs potentiellement incohérentes a été réalisée afin de s'assurer que les données respectent des limites logiques.

2.11.1 Âge des clients

L'âge des clients a été contrôlé afin d'identifier les valeurs inférieures à 0 ou supérieures à 100 ans.

Aucune valeur incohérente n'a été détectée.

TABLE 2.7 – Vérification de l'âge

Contrôle	Nombre d'erreurs
Âge inférieur à 0 ou supérieur à 100	0

2.11.2 Ancienneté des clients

La variable `TenureinMonths` a été contrôlée afin de détecter d'éventuelles valeurs négatives. Aucune durée d'abonnement incohérente n'a été détectée.

2.11.3 Variables financières

Les variables financières suivantes ont été contrôlées :

- MonthlyCharge;
- TotalCharges;
- TotalRefunds;
- TotalExtraDataCharges;
- TotalLongDistanceCharges;
- TotalRevenue.

Aucune valeur négative n'a été détectée dans ces variables.

TABLE 2.8 – Vérification des variables financières

Variable	Valeurs négatives
MonthlyCharge	0
TotalCharges	0
TotalRefunds	0
TotalExtraDataCharges	0
TotalLongDistanceCharges	0
TotalRevenue	0

Le contrôle du `SatisfactionScore` a également permis de vérifier que les valeurs appartiennent à l'intervalle attendu de 1 à 5.

2.12 Détection des valeurs atypiques

Après la suppression des variables jugées inutiles pour la modélisation, une analyse des valeurs atypiques a été réalisée sur les variables numériques restantes.

La détection des valeurs atypiques a été effectuée à l'aide de la méthode de l'intervalle interquartile, ou méthode *IQR* (*Interquartile Range*).

Pour chaque variable numérique, l'intervalle interquartile est calculé selon la formule :

$$IQR = Q_3 - Q_1$$

où Q_1 représente le premier quartile et Q_3 le troisième quartile.

Les bornes de détection sont ensuite définies par :

$$B_{\text{inf}} = Q_1 - 1.5 \times IQR$$

$$B_{\text{sup}} = Q_3 + 1.5 \times IQR$$

Toute observation située en dehors de ces bornes est considérée comme potentiellement atypique.

TABLE 2.9 – Résumé de la détection des valeurs atypiques

Variable	Nombre	Pourcentage
Age	0	0,00 %
NumberofDependents	1 627	23,10 %
Number_of_Referrals	676	9,60 %
TenureinMonths	0	0,00 %
AvgMonthlyLongDistanceCharges	0	0,00 %
AvgMonthlyGBDownload	362	5,14 %
MonthlyCharge	0	0,00 %
TotalCharges	0	0,00 %
TotalRefunds	525	7,45 %
TotalExtraDataCharges	728	10,34 %
TotalLongDistanceCharges	196	2,78 %
TotalRevenue	21	0,30 %
SatisfactionScore	922	13,09 %
ChurnScore	0	0,00 %
CLTV	0	0,00 %

Les résultats montrent notamment une proportion importante de valeurs potentiellement atypiques pour `NumberofDependents`, `SatisfactionScore`, `TotalExtraDataCharges` et `Number_of_Referrals`.

Cependant, la détection statistique d’une valeur atypique ne signifie pas nécessairement que celle-ci est incorrecte. Ces observations peuvent correspondre à des situations réelles rencontrées chez certains clients, notamment en ce qui concerne le nombre de personnes à charge, les dépenses supplémentaires ou le niveau de satisfaction.

Par conséquent, les valeurs atypiques n’ont pas été supprimées automatiquement. Elles ont été conservées afin d’éviter une perte d’information potentiellement importante pour l’analyse du comportement des clients.

Il convient également de préciser que les variables géographiques `ZipCode`, `Latitude`, `Longitude` et `Population` ne figurent pas dans cette analyse, car elles ont été supprimées précédemment en raison de leur faible pertinence pour l’objectif de prédiction du churn.

2.13 Résultat final du nettoyage

À l’issue du processus de nettoyage, le dataset conserve **7 043 observations** et comporte désormais **41 variables**, contre 50 variables initialement.

Les principales opérations réalisées au cours de cette étape sont résumées dans le tableau suivant.

TABLE 2.10 – Synthèse des opérations de nettoyage

Opération	Résultat
Vérification des doublons	Aucun doublon détecté
Traitement des valeurs manquantes	Aucune valeur manquante restante
Nettoyage des variables catégorielles	Aucun espace inutile détecté
Suppression des variables constantes	Country , State et Quarter supprimées
Suppression de l'identifiant	CustomerID supprimée
Suppression des variables géographiques	City , ZipCode , Latitude , Longitude et Population supprimées
Valeurs incohérentes	Aucune anomalie détectée
Détection des valeurs atypiques	Valeurs atypiques identifiées mais conservées
Dimensions finales	7 043 lignes $\times$ 41 variables

Au total, **9 variables** ont été supprimées lors du nettoyage initial : **CustomerID**, **Country**, **State**, **Quarter**, **City**, **ZipCode**, **Latitude**, **Longitude** et **Population**.

Le nombre d'observations reste inchangé, avec **7 043 clients**, tandis que le nombre de variables passe de **50 à 41**.

2.14 Conclusion

Le processus de nettoyage a permis d'obtenir un jeu de données plus cohérent et mieux adapté aux objectifs de l'étude.

Les doublons ont été vérifiés et aucune observation dupliquée n'a été détectée. Les valeurs manquantes identifiées dans les variables **Offer**, **InternetType**, **ChurnCategory** et **ChurnReason** ont été traitées, permettant d'obtenir un dataset sans valeur manquante.

Les variables catégorielles ont également été vérifiées afin d'éliminer les éventuels espaces inutiles. Les variables constantes, l'identifiant **CustomerID** ainsi que les variables géographiques jugées non nécessaires à l'objectif de prédiction ont été supprimés.

Les contrôles effectués sur les variables numériques n'ont révélé aucune valeur incohérente. Des valeurs potentiellement atypiques ont néanmoins été identifiées à l'aide de la méthode IQR. Elles n'ont pas été supprimées automatiquement, car leur caractère atypique ne signifie pas nécessairement qu'elles sont erronées ou inutiles pour l'analyse.

À l'issue de cette étape, le dataset obtenu contient **7 043 observations et 41 variables**. Il constitue ainsi une base propre et cohérente pour poursuivre le projet avec **l'analyse exploratoire des données (EDA)**.

Chapitre 3

Analyse exploratoire des données

Après le nettoyage des données, une analyse exploratoire a été réalisée afin de mieux comprendre la structure du portefeuille client et d'identifier les premiers facteurs associés au churn.

Cette analyse repose sur des analyses univariées et bivariées ainsi que sur l'étude des corrélations entre les variables numériques. Quatre visualisations principales ont été retenues afin de synthétiser les résultats obtenus.

3.1 Analyse univariée des variables clés

Après le nettoyage, chaque variable a été explorée individuellement afin de comprendre la répartition des clients et de repérer les premiers signaux liés au churn.

3.1.1 Distribution de la variable cible

La variable `ChurnLabel` constitue la variable cible du problème de classification. Elle permet de distinguer les clients ayant quitté l'entreprise de ceux qui sont restés.

La base de données présente un certain déséquilibre entre les deux classes : environ trois clients sur quatre restent fidèles, tandis qu'un peu plus d'un client sur quatre a quitté l'entreprise.

Le dataset contient ainsi **1 869 clients ayant quitté l'entreprise**, soit environ **26,54 %**, contre **5 174 clients restés**, soit **73,46 %**.




FIGURE 3.1 – Répartition des clients selon le statut de churn

Cette répartition met en évidence un déséquilibre entre les deux classes. Ce déséquilibre devra être pris en compte lors de la modélisation prédictive, notamment dans le choix des métriques d'évaluation et dans l'interprétation des performances des modèles.

3.1.2 Statistiques descriptives

Les principales statistiques descriptives des variables numériques permettent de mieux caractériser le portefeuille client.

TABLE 3.1 – Statistiques descriptives des principales variables

Variable	Moyenne	Intervalle observé
Âge	46,5	19 – 80
Ancienneté (mois)	32	1 – 72
Charges mensuelles	64,76	18,25 – 118,75
Charges totales	2 280,38	18,80 – 8 684,80
Revenu total	3 034,38	21,36 – 11 979,34
Score satisfaction	3,24	1 – 5
CLTV	4 400,30	2 003 – 6 500
Consommation Internet (Go)	20,52	0 – 85

Les variables financières et d'usage montrent une dispersion importante, tandis que la satisfaction et l'ancienneté constituent des variables particulièrement intéressantes pour l'analyse du comportement des clients.

3.1.3 Lecture des principales variables

- **Âge** : la majorité des clients se situe entre 46 et 60 ans, avec également une présence importante de clients seniors. La clientèle apparaît donc relativement diverse.
- **Ancienneté** : les clients sont présents depuis différentes périodes, avec une présence légèrement plus importante de clients récents. Cela souligne l'importance de la

fidélisation dès le début de la relation client.

- **Charges mensuelles et totales** : les dépenses des clients se situent généralement à un niveau moyen, mais certains clients présentent des montants nettement plus élevés.
- **Score de satisfaction** : la satisfaction des clients se situe globalement à un niveau moyen. Une partie des clients présente cependant un niveau de satisfaction faible, ce qui peut constituer un signal potentiel de départ.
- **CLTV** : la valeur des clients est généralement intermédiaire, mais certains clients présentent une forte valeur pour l'entreprise. La CLTV peut ainsi être considérée conjointement avec la satisfaction afin d'identifier les clients présentant un enjeu important pour la fidélisation.

3.2 Analyse des variables catégorielles

Cette analyse permet d'étudier les principales caractéristiques catégorielles du portefeuille client, notamment le type de contrat, le mode de paiement, le type d'accès Internet et le statut client.




FIGURE 3.2 – Répartition des principales variables catégorielles

La figure met en évidence plusieurs caractéristiques importantes :

- **Contrat** : les contrats mensuels dominent nettement, avec environ 51,25 % des clients. Cette situation correspond à une relation plus flexible et constitue un élément important dans l'analyse du risque de départ.
- **Paiement** : le prélèvement bancaire constitue le principal mode de paiement, avec environ 55,5 % des clients, suivi de la carte bancaire avec 39,03 %.
- **Internet** : la fibre optique constitue le type d'accès le plus courant. Les offres DSL et les clients ne disposant pas d'Internet restent également représentés.
- **Statut client** : la majorité des clients est encore active, tandis qu'environ 26,5 % des clients ont quitté l'entreprise.

Globalement, les variables catégorielles mettent en évidence un portefeuille client hétérogène, avec une forte présence des contrats mensuels et du prélèvement bancaire.

3.3 Analyse bivariée : facteurs influençant le churn

L'analyse bivariée consiste à étudier la relation entre différentes variables explicatives et la variable cible `ChurnLabel`. Elle permet d'identifier les différences entre les clients qui restent et ceux qui quittent l'entreprise.

Treize facteurs ont été examinés. Les principaux résultats sont présentés dans la figure suivante.




FIGURE 3.3 – Principaux multiplicateurs de risque de churn

Les principaux résultats peuvent être résumés comme suit :

TABLE 3.2 – Principaux facteurs associés au churn

Facteur	Constat
Contract	Les contrats mensuels présentent le risque de churn le plus élevé par rapport aux contrats de longue durée.
SatisfactionScore	Le score moyen de satisfaction est nettement plus faible chez les clients ayant quitté l'entreprise.
TenureinMonths	Les clients ayant quitté l'entreprise présentent une ancienneté moyenne plus faible.
OnlineSecurity / PremiumTechSupport	L'absence de ces services est associée à un taux de churn plus important.
InternetType	La fibre optique présente le niveau de churn le plus élevé parmi les différents types d'accès.
SeniorCitizen	Les clients seniors présentent un niveau de churn supérieur aux autres clients.
PaymentMethod	Certains modes de paiement sont associés à davantage de départs, tandis que la carte bancaire présente un taux plus faible.
MonthlyCharge	Les clients ayant quitté l'entreprise présentent en moyenne des charges mensuelles plus élevées.
TotalRevenue	Le revenu total est plus élevé chez les clients restés dans l'entreprise.
Age	Les clients ayant quitté l'entreprise sont en moyenne légèrement plus âgés.
Number_of_Referrals	Les clients fidèles recommandent davantage l'entreprise.
ChurnScore	Le score de churn est nettement plus élevé chez les clients ayant quitté l'entreprise.

Ces résultats montrent que l'engagement contractuel, la satisfaction et l'ancienneté constituent des facteurs particulièrement importants dans l'analyse du risque de départ.

3.4 Variables directement liées au churn

L'analyse des variables directement associées au départ permet également d'identifier les principales catégories et raisons de résiliation.

La catégorie liée à la concurrence est la plus représentée (**44,99 %**), suivie de la satisfaction (**33,76 %**) et de l'attitude (**21,25 %**).

Les raisons de résiliation montrent également une présence importante des facteurs liés à la concurrence et au service client. Ces résultats soulignent l'importance de l'expérience client dans le phénomène de churn.

Concernant la sécurité en ligne, environ 63 % des clients n'ont pas souscrit à cette option. Cette caractéristique peut refléter des différences dans les usages et les besoins des clients.

3.5 Analyse des corrélations entre variables numériques

Une matrice de corrélation de Pearson a été calculée afin de mesurer l'intensité et le sens des relations linéaires entre les variables numériques.

Les coefficients de corrélation r varient entre -1 et $+1$. Plus la valeur absolue du coefficient est élevée, plus la relation linéaire entre deux variables est importante.

Les variables `ZipCode`, `Latitude`, `Longitude` et `Population` ont été exclues de cette analyse, car elles sont moins directement pertinentes pour étudier les relations entre les principales caractéristiques des clients.




FIGURE 3.4 – Matrice de corrélation des principales variables numériques

3.5.1 Corrélations très fortes

Plusieurs relations présentent une corrélation supérieure à 0,80 :

- **TotalRevenue** ↔ **TotalCharges** : $r = 0,97$. Cette relation très forte indique une forte dépendance entre les deux montants cumulés.
- **TenureinMonths** ↔ **TotalRevenue** : $r = 0,85$. Les clients les plus anciens génèrent généralement davantage de revenus cumulés.
- **TenureinMonths** ↔ **TotalCharges** : $r = 0,83$. L'ancienneté est fortement associée à l'accumulation des charges au cours de la relation client.

3.5.2 Corrélations fortes

La variable **TotalLongDistanceCharges** présente une corrélation importante avec **TotalRevenue**, avec $r = 0,78$.

Cette relation montre que les usages supplémentaires contribuent de manière significative au revenu global généré par le client.

3.5.3 Corrélation négative importante

Une relation négative modérée est observée entre **SatisfactionScore** et **ChurnScore**, avec $r = -0,50$.

Cette relation indique que les clients présentant une satisfaction plus élevée tendent à avoir un score de churn plus faible.

3.5.4 Implications pour la modélisation

L'analyse des corrélations permet de mettre en évidence plusieurs points importants pour la suite du projet et pour la sélection des variables utilisées dans la modélisation.

- certaines variables numériques présentent une forte redondance informationnelle ;
- **TotalRevenue** et **TotalCharges** présentent une très forte corrélation positive ($r = 0,97$), indiquant que ces deux variables apportent des informations fortement similaires ;
- afin de limiter la redondance informationnelle et de réduire le risque de multicollinéarité, la variable **TotalCharges** a été supprimée, tandis que **TotalRevenue** a été conservée ;
- **TenureinMonths** présente également une forte corrélation avec les variables financières cumulées, notamment **TotalRevenue** ($r = 0,85$), ce qui est cohérent avec l'accumulation des revenus au cours de la durée d'abonnement ;
- **SatisfactionScore** présente une relation intéressante avec le phénomène de churn et constitue ainsi une variable potentiellement informative pour la prédiction.

La suppression de **TotalCharges** permet ainsi de conserver une représentation plus concise des informations financières tout en limitant la redondance entre les variables. Cette décision est prise sur la base de l'analyse exploratoire et sera prise en compte lors de la préparation finale des données pour la modélisation.

Ainsi, l'analyse des corrélations constitue une étape importante dans la sélection des variables et dans la préparation des données pour la construction des modèles de Machine Learning.

““latex

Chapitre 4

Démarche et méthodologie de modélisation

4.1 Introduction

Après le nettoyage et l'analyse exploratoire des données, les données sont préparées afin de pouvoir être utilisées par les algorithmes de Machine Learning. L'objectif est de construire un modèle capable de prédire si un client risque de quitter l'entreprise (*Churn*).

La méthodologie suivie comprend la définition de la variable cible, la suppression des variables présentant un risque de fuite de données, la séparation des données, l'encodage des variables catégorielles et la standardisation des variables numériques. Deux configurations sont ensuite étudiées afin d'analyser l'influence de `SatisfactionScore`. [?]

4.2 Préparation des données

4.2.1 Définition de la variable cible

La variable cible utilisée dans ce projet est `ChurnLabel`. Elle indique si un client a quitté ou non l'entreprise. La valeur *No* est remplacée par 0 et la valeur *Yes* par 1 afin d'obtenir une variable binaire adaptée aux algorithmes de classification.

TABLE 4.1 – Encodage de la variable cible

Valeur	Encodage
<i>No</i>	0
<i>Yes</i>	1

4.2.2 Prévention de la fuite de données

Afin d'éviter que le modèle utilise des informations directement liées au churn, quatre variables sont supprimées : `ChurnScore`, `ChurnCategory`, `ChurnReason` et `CustomerStatus`. Après cette suppression, le jeu de données contient 35 variables explicatives.

4.2.3 Séparation des données

Les données sont divisées en deux parties : 80 % pour l'entraînement et 20 % pour le test. Une stratification est utilisée afin de conserver une répartition similaire des classes dans les deux ensembles.

TABLE 4.2 – Répartition des données

Ensemble	Clients	Variables
Entraînement	5 634	35
Test	1 409	35
Total	7 043	35

4.2.4 Encodage et standardisation

Les 35 variables comprennent 13 variables numériques et 22 variables catégorielles.

Encodage des variables catégorielles

Les variables catégorielles sont transformées à l'aide du **Frequency Encoding**. Cette méthode remplace chaque catégorie par sa fréquence d'apparition dans les données d'entraînement.

Les fréquences sont calculées uniquement à partir de l'ensemble d'entraînement, puis appliquées à l'ensemble de test. Ainsi, les informations du jeu de test ne sont pas utilisées lors de l'apprentissage.

Standardisation des variables numériques

Les variables numériques sont standardisées à l'aide de **StandardScaler**. Cette transformation permet de placer les variables numériques sur une échelle comparable.

Le **StandardScaler** est ajusté uniquement sur l'ensemble d'entraînement, puis appliqué à l'ensemble de test. Les données sont ainsi préparées avant leur utilisation par les algorithmes de Machine Learning.

4.3 Algorithmes utilisés

Cinq algorithmes de classification sont utilisés pour prédire le *Churn*. Chaque algorithme utilise une méthode différente pour analyser les caractéristiques des clients et déterminer s'ils sont susceptibles de quitter l'entreprise.

4.3.1 Régression Logistique

La Régression Logistique cherche à déterminer la probabilité qu'un client appartienne à la classe *Churn* ou *No Churn*. Elle combine les différentes caractéristiques du client et produit une probabilité comprise entre 0 et 1. Cette probabilité est ensuite comparée à un seuil afin de déterminer la classe prédite.




FIGURE 4.1 – Principe de la Régression Logistique

4.3.2 Arbre de Décision

L'Arbre de Décision fonctionne comme une succession de questions. À chaque étape, il choisit une caractéristique et une règle permettant de séparer les clients en différents groupes. Le processus continue jusqu'à atteindre une décision finale, par exemple *Churn* ou *No Churn*.




FIGURE 4.2 – Principe de l'Arbre de Décision

4.3.3 Random Forest

Le Random Forest est composé de plusieurs Arbres de Décision. Chaque arbre effectue sa propre prédiction à partir des données. Les prédictions de tous les arbres sont ensuite combinées afin d'obtenir la décision finale. Cette combinaison permet généralement d'obtenir

un modèle plus robuste qu'un seul arbre.




FIGURE 4.3 – Principe du Random Forest

4.3.4 Gradient Boosting

Le Gradient Boosting construit les arbres de manière successive. Le premier arbre réalise une première prédiction, puis les arbres suivants cherchent principalement à corriger les erreurs des arbres précédents. Les différents arbres sont finalement combinés pour obtenir une prédiction plus précise.




FIGURE 4.4 – Principe du Gradient Boosting

4.3.5 K-Nearest Neighbors (KNN)

Le K-Nearest Neighbors (KNN) prédit la classe d'un nouveau client en recherchant les clients qui lui ressemblent le plus dans les données. Il sélectionne un nombre donné de voisins proches, puis observe leur classe. La classe la plus représentée parmi ces voisins devient la classe prédite pour le nouveau client.




FIGURE 4.5 – Principe du K-Nearest Neighbors

4.4 Démarche de modélisation

4.4.1 Optimisation des hyperparamètres

Après la préparation des données, les cinq modèles sont optimisés afin de déterminer la configuration la plus adaptée à chaque algorithme.

Pour cela, plusieurs valeurs d'hyperparamètres sont définies pour chaque modèle et testées à l'aide de `GridSearchCV`. Cette méthode permet d'examiner différentes combinaisons de paramètres et de sélectionner celle qui obtient le meilleur résultat selon le **F1-score**.

Le F1-score est choisi comme critère de sélection car il prend simultanément en compte la **Precision** et le **Recall**. Il permet ainsi de rechercher un équilibre entre la capacité du modèle à effectuer des prédictions correctes et sa capacité à détecter les clients ayant réellement churné.

4.4.2 Validation croisée

La recherche des meilleurs hyperparamètres est réalisée avec une validation croisée en cinq parties (*5-fold cross-validation*).

L'ensemble d'entraînement est divisé en cinq sous-ensembles. À chaque itération, quatre sous-ensembles sont utilisés pour l'entraînement et le cinquième pour la validation. Cette opération est répétée cinq fois afin que chaque sous-ensemble soit utilisé une fois pour la validation.

Le F1-score moyen obtenu sur les cinq validations est utilisé par `GridSearchCV` pour sélectionner la meilleure combinaison d'hyperparamètres.

4.4.3 Évaluation sur l'ensemble de test

Après la sélection des meilleurs hyperparamètres, chaque modèle est entraîné avec la configuration retenue puis évalué sur l'ensemble de test.

Les performances sont mesurées à l'aide de quatre métriques : **Accuracy**, **Precision**, **Recall** et **F1-score**.

Cette évaluation permet de mesurer la capacité des modèles à généraliser sur des données qui n'ont pas été utilisées lors de leur apprentissage.

4.4.4 Sélection du meilleur modèle

Les résultats obtenus sur l'ensemble de test sont comparés afin d'identifier le modèle offrant le meilleur compromis entre Precision et Recall.

Le modèle présentant le meilleur **F1-score** est retenu comme modèle final pour la suite de l'étude.

4.4.5 Validation croisée

Lors de l'optimisation, une validation croisée en cinq parties (*5-fold cross-validation*) est utilisée.

L'ensemble d'entraînement est divisé en cinq parties. Le modèle est entraîné sur quatre parties et validé sur la partie restante. Cette opération est répétée cinq fois afin que chaque partie soit utilisée une fois pour la validation.

Le score moyen obtenu sur les cinq validations permet de sélectionner une configuration plus fiable et de limiter la dépendance à une seule séparation des données.

Default holdout and cross-validation




FIGURE 4.6 – 5-fold cross-validation

4.4.6 Évaluation finale

Après la sélection des meilleurs hyperparamètres, chaque modèle optimisé est évalué sur l'ensemble de test. Cette évaluation permet de mesurer sa capacité à prédire correctement le churn sur de nouvelles données.

Matrice de confusion

La matrice de confusion permet de comparer les prédictions du modèle avec les valeurs réelles. Elle permet d'identifier les prédictions correctes et les erreurs du modèle.

Elle contient quatre éléments :

- **Vrai Positif (TP)** : le client a churné et le modèle prédit un churn ;
- **Vrai Négatif (TN)** : le client n'a pas churné et le modèle prédit un non-churn ;
- **Faux Positif (FP)** : le client n'a pas churné mais le modèle prédit un churn ;
- **Faux Négatif (FN)** : le client a churné mais le modèle ne le détecte pas.

Métriques d'évaluation

Les performances des modèles sont mesurées avec quatre métriques :

- **Accuracy** : proportion des prédictions correctes.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Precision** : parmi les clients prédits comme ayant churné, proportion de ceux qui ont réellement churné.

$$Precision = \frac{TP}{TP + FP}$$

- **Recall** : parmi les clients ayant réellement churné, proportion de ceux correctement détectés.

$$Recall = \frac{TP}{TP + FN}$$

- **F1-score** : moyenne harmonique entre la Precision et le Recall.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Dans cette étude, le **F1-score** est utilisé comme métrique principale pour comparer les modèles, car il permet de prendre en compte à la fois la Precision et le Recall.

4.4.7 Comparaison des deux configurations

Deux configurations sont ensuite comparées afin d'étudier l'influence de **SatisfactionScore**.

Dans la première configuration, **SatisfactionScore** est conservée parmi les variables explicatives. Dans la seconde, cette variable est supprimée.

Les performances obtenues avec les deux configurations sont comparées afin de déterminer son influence sur la prédiction du churn et de choisir la configuration la plus performante.

4.4.8 Sélection du modèle final

À partir des résultats obtenus, le modèle présentant le meilleur F1-score est retenu comme modèle final.

Le modèle sélectionné est ensuite utilisé pour l'analyse de la matrice de confusion et de l'importance des variables. Enfin, il est sauvegardé afin d'être intégré dans l'application interactive développée avec **Streamlit**.

Chapitre 5

Évaluation et résultats

5.1 Introduction

Cette partie présente les résultats obtenus après l'optimisation des modèles de classification. Les modèles sont comparés à l'aide de l'Accuracy, de la Precision, du Recall et du F1-score. L'analyse porte également sur la matrice de confusion du modèle retenu, ainsi que sur l'importance des variables utilisées pour la prédiction du churn.

5.2 Résultats avec SatisfactionScore

5.2.1 Optimisation

Afin d'améliorer les performances des modèles, une recherche des meilleurs hyperparamètres est réalisée à l'aide de `GridSearchCV`.

Pour chaque modèle, plusieurs combinaisons d'hyperparamètres sont testées à l'aide d'une validation croisée en cinq parties (*5-fold cross-validation*). La combinaison obtenant le meilleur **F1-score** est ensuite retenue.

Les valeurs des hyperparamètres testées pour chaque modèle sont présentées ci-dessous.

Régression Logistique

Pour la Régression Logistique, les hyperparamètres suivants sont testés :

- `C` = [0.01, 0.1, 1, 10] : contrôle la force de la régularisation.
- `solver` = [`liblinear`, `lbfgs`] : définit l'algorithme utilisé pour optimiser le modèle.

Arbre de Décision

Pour l'Arbre de Décision, les hyperparamètres suivants sont testés :

- `max_depth` = [3, 5, 10, None] : définit la profondeur maximale de l'arbre.
- `min_samples_split` = [2, 5, 10] : définit le nombre minimal d'observations nécessaires pour diviser un nœud.

- `min_samples_leaf = [1, 2, 4]` : définit le nombre minimal d’observations présentes dans une feuille.

Random Forest

Pour le modèle Random Forest, les hyperparamètres suivants sont testés :

- `n_estimators = [100, 200]` : définit le nombre d’arbres utilisés dans la forêt.
- `max_depth = [None, 10, 20]` : définit la profondeur maximale des arbres.
- `min_samples_split = [2, 5]` : définit le nombre minimal d’observations nécessaires pour diviser un nœud.
- `min_samples_leaf = [1, 2]` : définit le nombre minimal d’observations présentes dans une feuille. ““

Gradient Boosting

Pour le modèle Gradient Boosting, les hyperparamètres suivants sont testés :

- `n_estimators = [100, 200]` : définit le nombre d’arbres utilisés par le modèle.
- `learning_rate = [0.05, 0.1]` : contrôle la contribution de chaque arbre à la construction du modèle final.
- `max_depth = [2, 3]` : définit la profondeur maximale des arbres.

K-Nearest Neighbors (KNN)

Pour le modèle KNN, les hyperparamètres suivants sont testés :

- `n_neighbors = [3, 5, 7, 9, 11]` : définit le nombre de voisins utilisés pour effectuer la prédiction.
- `weights = [uniform, distance]` : définit la manière dont les voisins contribuent à la prédiction.
- `p = [1, 2]` : définit la métrique utilisée pour calculer la distance entre les observations.

Sélection du meilleur modèle

Après avoir testé les différentes combinaisons d’hyperparamètres, la configuration obtenant le meilleur **F1-score** est retenue pour chaque modèle.

Les performances des modèles optimisés sont ensuite comparées à l’aide des métriques présentées précédemment afin d’identifier le modèle le plus performant pour la prédiction du churn.

Meilleurs hyperparamètres

Les meilleures combinaisons obtenues par `GridSearchCV` sont présentées dans le tableau suivant.

TABLE 5.1 – Meilleurs hyperparamètres après optimisation

Modèle	Meilleurs hyperparamètres	F1 CV
Logistic Regression	$C = 10$, solver= lbfgs	0.9198
Decision Tree	max_depth=10, min_samples_split=2, min_samples_leaf=4	0.9022
Random Forest	n_estimators=100, max_depth=20, min_samples_split=2, min_samples_leaf=1	0.9271
Gradient Boosting	n_estimators=200, learning_rate=0.1, max_depth=3	0.9270
KNN	n_neighbors=11, weights= distance , p=1	0.8791

5.2.2 Performances finales

Les performances finales des modèles optimisés sont présentées dans le tableau suivant.

TABLE 5.2 – Performances finales avec SatisfactionScore

Modèle	Accuracy	Precision	Recall	F1-score
Gradient Boosting	0.960256	0.954286	0.893048	0.922652
Logistic Regression	0.959546	0.946479	0.898396	0.921811
Random Forest	0.959546	0.973134	0.871658	0.919605
Decision Tree	0.957417	0.956395	0.879679	0.916435
KNN	0.938254	0.941538	0.818182	0.875536

Le **Gradient Boosting** obtient le meilleur F1-score sur l'ensemble de test avec une valeur de **0.922652**, soit **92.27 %**. Il est donc retenu comme modèle final de cette configuration.

5.3 Évaluation du modèle final

Le modèle final est un **Gradient Boosting** configuré avec les paramètres suivants :

- `n_estimators = 200`;
- `learning_rate = 0.1`;
- `max_depth = 3`.

5.3.1 Matrice de confusion

La matrice de confusion permet de comparer les prédictions du modèle avec les valeurs réelles. Elle permet ainsi d'identifier les prédictions correctes et les erreurs de classification.




FIGURE 5.1 – Matrice de confusion du Gradient Boosting avec SatisfactionScore

La matrice montre que le modèle classe correctement **1019 clients sans churn** et détecte correctement **334 clients ayant churné**.

Il produit également **16 faux positifs**, correspondant aux clients sans churn classés comme ayant churné, et **40 faux négatifs**, correspondant aux clients ayant churné mais non détectés par le modèle.

Ainsi, sur les **1409 clients** de l'ensemble de test, **1353 sont correctement classés**.

5.3.2 Métriques d'évaluation

À partir des valeurs de la matrice de confusion, les principales métriques d'évaluation sont calculées : Accuracy, Precision, Recall et F1-score.

TABLE 5.3 – Performances du Gradient Boosting avec SatisfactionScore

Métrique	Valeur
Accuracy	96.03 %
Precision	95.43 %
Recall	89.30 %
F1-score	92.27 %

L'**Accuracy** de **96.03 %** indique que la majorité des clients sont correctement classés.

La **Precision** de **95.43 %** signifie que la majorité des clients prédits comme ayant churné ont réellement churné.

Le **Recall** de **89.30 %** indique que le modèle détecte correctement la majorité des clients ayant réellement churné.

Enfin, le **F1-score** de **92.27 %** montre un bon équilibre entre la Precision et le Recall.

5.3.3 Importance des variables

L'importance des variables est analysée à partir de l'attribut `feature_importances_` du modèle **Gradient Boosting**. Cette méthode mesure la contribution relative des variables aux décisions prises par les arbres du modèle.

Les huit variables les plus importantes sont présentées dans le tableau suivant.

TABLE 5.4 – Principales variables avec SatisfactionScore

Variable	Importance
SatisfactionScore	0.880423
OnlineSecurity	0.023931
Contract	0.020729
TenureinMonths	0.014447
TotalRevenue	0.008931
MonthlyCharge	0.008216
Number_of_Referrals	0.007942
Age	0.005483




FIGURE 5.2 – Importance des variables avec SatisfactionScore

La variable **SatisfactionScore** présente une importance de **0.880423**, nettement supérieure à celle des autres variables. Elle constitue donc la variable la plus importante dans les décisions du modèle.

Les variables **OnlineSecurity**, **Contract** et **TenureinMonths** occupent les positions suivantes, mais avec des importances beaucoup plus faibles.

Cette forte importance de **SatisfactionScore** motive l'étude d'une seconde configuration dans laquelle cette variable est supprimée afin d'observer son influence sur les performances du modèle.

5.4 Résultats sans SatisfactionScore

Dans cette configuration, `SatisfactionScore` est supprimée. Le nombre de variables explicatives passe de 35 à 34.

5.4.1 Optimisation

Afin d'améliorer les performances des modèles, une recherche des meilleurs hyperparamètres est réalisée à l'aide de `GridSearchCV`.

Pour chaque modèle, plusieurs combinaisons d'hyperparamètres sont testées à l'aide d'une validation croisée en cinq parties (*5-fold cross-validation*). La combinaison obtenant le meilleur **F1-score** est ensuite retenue.

Les valeurs testées pour chaque modèle sont présentées ci-dessous.

Régression Logistique

Pour la Régression Logistique, les hyperparamètres suivants sont testés :

- `C` = [0.01, 0.1, 1, 10] : contrôle la force de la régularisation.
- `solver` = [`liblinear`, `lbfgs`] : définit l'algorithme utilisé pour l'optimisation.

Arbre de Décision

Pour l'Arbre de Décision, les hyperparamètres suivants sont testés :

- `max_depth` = [3, 5, 10, `None`] : définit la profondeur maximale de l'arbre.
- `min_samples_split` = [2, 5, 10] : définit le nombre minimal d'observations nécessaires pour diviser un nœud.
- `min_samples_leaf` = [1, 2, 4] : définit le nombre minimal d'observations dans une feuille.

Random Forest

Pour le modèle Random Forest, les hyperparamètres suivants sont testés :

- `n_estimators` = [100, 200] : définit le nombre d'arbres utilisés dans la forêt.
- `max_depth` = [`None`, 10, 20] : définit la profondeur maximale des arbres.
- `min_samples_split` = [2, 5] : définit le nombre minimal d'observations nécessaires pour diviser un nœud.
- `min_samples_leaf` = [1, 2] : définit le nombre minimal d'observations dans une feuille.

Gradient Boosting

Pour le modèle Gradient Boosting, les hyperparamètres suivants sont testés :

- `n_estimators` = [100, 200] : définit le nombre d'arbres utilisés par le modèle.

- `learning_rate` = [0.05, 0.1] : contrôle la contribution de chaque arbre au modèle final.
- `max_depth` = [2, 3] : définit la profondeur maximale des arbres.

K-Nearest Neighbors (KNN)

Pour le modèle KNN, les hyperparamètres suivants sont testés :

- `n_neighbors` = [3, 5, 7, 9, 11] : définit le nombre de voisins utilisés pour effectuer la prédiction.
- `weights` = [uniform, distance] : définit la manière dont les voisins contribuent à la prédiction.
- `p` = [1, 2] : définit la métrique de distance utilisée.

Les meilleures combinaisons obtenues sont présentées dans le tableau suivant.

TABLE 5.5 – Meilleurs hyperparamètres sans SatisfactionScore

Modèle	Meilleurs hyperparamètres	F1 CV
Logistic Regression	<code>C = 10, solver=liblinear</code>	0.6873
Decision Tree	<code>max_depth=10, min_samples_split=2, min_samples_leaf=2</code>	0.6338
Random Forest	<code>n_estimators=200, max_depth=10, min_samples_split=2, min_samples_leaf=1</code>	0.6785
Gradient Boosting	<code>n_estimators=200, learning_rate=0.05, max_depth=3</code>	0.6906
KNN	<code>n_neighbors=9, weights=distance, p=1</code>	0.6180

5.4.2 Performances finales

Les modèles optimisés sont ensuite évalués sur l'ensemble de test. Les résultats obtenus sont présentés dans le tableau suivant.

TABLE 5.6 – Performances finales sans SatisfactionScore

Modèle	Accuracy	Precision	Recall	F1-score
Gradient Boosting	0.854507	0.758410	0.663102	0.707561
Logistic Regression	0.844571	0.723343	0.671123	0.696255
Random Forest	0.846700	0.766892	0.606952	0.677612
Decision Tree	0.828247	0.717105	0.582888	0.643068
KNN	0.802697	0.643713	0.574866	0.607345

Le **Gradient Boosting** obtient le meilleur F1-score sur l'ensemble de test avec une valeur de **0.707561**, soit **70.76 %**. Il est donc retenu comme modèle final de cette configuration.

5.4.3 Matrice de confusion

La matrice de confusion permet de comparer les prédictions du modèle avec les valeurs réelles et d'identifier les classifications correctes et incorrectes.




FIGURE 5.3 – Matrice de confusion du Gradient Boosting sans SatisfactionScore

Le modèle détecte correctement **248 clients ayant réellement churné**, tandis que **126 clients ayant churné** ne sont pas détectés.

Il classe également correctement **956 clients sans churn** et classe à tort **79 clients sans churn** comme ayant churné.

Ainsi, sur les **1409 clients** de l'ensemble de test, **1204 clients sont correctement classés**.

5.4.4 Métriques d'évaluation

À partir des valeurs obtenues dans la matrice de confusion, les performances du modèle sont évaluées à l'aide de l'Accuracy, de la Precision, du Recall et du F1-score.

TABLE 5.7 – Performances du Gradient Boosting sans SatisfactionScore

Métrique	Valeur
Accuracy	85.45 %
Precision	75.84 %
Recall	66.31 %
F1-score	70.76 %

L'**Accuracy** de **85.45 %** indique que la majorité des clients sont correctement classés.

La **Precision** de **75.84 %** signifie que parmi les clients prédits comme ayant churné, une grande partie a réellement churné.

Le **Recall** de **66.31 %** indique que le modèle détecte environ deux tiers des clients ayant réellement churné.

Enfin, le **F1-score** de **70.76 %** représente l'équilibre entre la Precision et le Recall.

5.4.5 Importance des variables

Après suppression de `SatisfactionScore`, les variables les plus importantes sont déterminées à partir de l'attribut `feature_importances_` du modèle **Gradient Boosting**. Cette méthode mesure la contribution relative des variables dans les décisions prises par les arbres du modèle.

Les huit variables les plus importantes sont présentées dans le tableau suivant.

TABLE 5.8 – Principales variables sans `SatisfactionScore`

Variable	Importance
Contract	0.389325
Number_of_Referrals	0.115483
TenureinMonths	0.072653
MonthlyCharge	0.064511
Age	0.058282
InternetType	0.039314
TotalRevenue	0.039165
NumberofDependents	0.034755

La variable `Contract` devient la plus importante avec une importance de **0.389325**. Elle est suivie par `Number_of_Referrals`, `TenureinMonths` et `MonthlyCharge`.




FIGURE 5.4 – Importance des variables sans `SatisfactionScore`

La suppression de `SatisfactionScore` permet ainsi de mieux observer l'influence des autres caractéristiques des clients, notamment le type de contrat, le nombre de recommandations, l'ancienneté et les charges mensuelles.

5.5 Comparaison des deux configurations

La comparaison permet de mesurer l'influence de `SatisfactionScore` sur les performances du modèle final.

TABLE 5.9 – Comparaison des performances finales

Métrique	Avec SatisfactionScore	Sans SatisfactionScore
Accuracy	96.03 %	85.45 %
Precision	95.43 %	75.84 %
Recall	89.30 %	66.31 %
F1-score	92.27 %	70.76 %

Les résultats montrent une différence importante entre les deux configurations. Le F1-score passe de **70.76 %** sans SatisfactionScore à **92.27 %** lorsqu'elle est conservée.

5.6 Conclusion

L'étude montre que le **Gradient Boosting** est le modèle le plus performant dans les deux configurations étudiées. Avec SatisfactionScore, il atteint un F1-score de **92.27 %**, contre **70.76 %** sans cette variable.

Le modèle final retenu est donc le **Gradient Boosting avec SatisfactionScore**, avec les paramètres `n_estimators = 200`, `learning_rate = 0.1` et `max_depth = 3`. Il sera ensuite sauvegardé et intégré dans l'application interactive développée avec **Streamlit**.

Chapitre 6

Mise en application avec Streamlit

Après la sélection du modèle final, une application interactive a été développée avec **Streamlit** afin de faciliter son utilisation pour la prédiction du churn.

Avant son intégration dans l'application, le modèle **Gradient Boosting** ainsi que les différents éléments nécessaires au prétraitement des données ont été sauvegardés.

6.1 Sauvegarde du modèle

Le modèle final a été sauvegardé au format `.pkl` à l'aide de la bibliothèque `joblib`. Cette sauvegarde permet de réutiliser directement le modèle entraîné sans avoir à effectuer de nouveau son entraînement.

Le modèle a ainsi été enregistré dans le fichier `gradient_boosting_churn.pkl`.

6.2 Sauvegarde des éléments de prétraitement

Afin de garantir que les nouvelles données saisies dans l'application soient traitées de la même manière que les données d'entraînement, les éléments nécessaires au prétraitement ont également été sauvegardés.

Il s'agit notamment :

- du **Scaler** utilisé pour les variables numériques ;
- des **fréquences des variables catégorielles** utilisées lors de l'encodage ;
- des informations relatives aux variables utilisées par le modèle.

Ces éléments sont sauvegardés dans les fichiers `scaler.pkl`, `frequency_encodings.pkl` et `model_information.pkl`.

6.3 Application Streamlit

L'application développée avec **Streamlit** permet à l'utilisateur de renseigner les caractéristiques d'un client. Les informations saisies sont ensuite prétraitées à l'aide des éléments sauvegardés, puis transmises au modèle de **Gradient Boosting**.

L'application fournit finalement une prédiction indiquant si le client présente un risque de churn.

Cette étape permet ainsi de transformer le modèle de Machine Learning en une application simple et interactive, facilitant son utilisation pour la prédiction de nouveaux clients.

Analyse du churn client

Analysez le profil d'un client et estimez son risque de résiliation.

Profil Services Contrat & facturation Usage & valeur

Informations générales

Âge: 46 Marié(e): No Recommandé par un ami: No

Genre: Male Personnes à charge: No Nombre de recommandations: 1

Moins de 30 ans: No Nombre de personnes à charge: 0 Ancienneté (mois): 12

Senior Citizen: No Ville: Los Angeles

Analyse

Lorsque toutes les informations sont renseignées, lancez l'analyse pour obtenir la prédiction.

Analyser le risque de churn

Résultat de l'analyse

☒ Pas de churn

Le modèle estime que ce client présente un faible risque de quitter l'entreprise.

Probabilité de churn: **0.98%**

☒ Risque faible : le client semble relativement stable selon le modèle.

[Voir les données transmises au modèle](#)

FIGURE 6.1 – Interface de l'application Streamlit

6.4 Conclusion

La mise en place de l'application Streamlit constitue la dernière étape du projet. Elle permet de rendre le modèle final accessible à travers une interface interactive et d'utiliser ses prédictions sur de nouveaux profils clients.

Conclusion générale

Ce projet a permis de mettre en place une démarche complète d'analyse et de prédiction du churn client, depuis le nettoyage des données jusqu'à la mise en application du modèle.

L'analyse exploratoire a permis d'identifier plusieurs facteurs associés au churn, notamment le type de contrat, l'ancienneté, les charges mensuelles et le niveau de satisfaction des clients.

Cinq modèles de classification ont ensuite été entraînés, comparés et optimisés à l'aide de **GridSearchCV** et d'une validation croisée en cinq parties. Deux configurations ont été étudiées afin d'évaluer l'influence de la variable **SatisfactionScore**.

Les résultats montrent que le Gradient Boosting avec **SatisfactionScore** est le modèle le plus performant. Il atteint un **F1-score de 92,27 %**, avec une Accuracy de **96,03 %**, une Precision de **95,43 %** et un Recall de **89,30 %** sur l'ensemble de test.

Enfin, le modèle retenu ainsi que les éléments nécessaires au prétraitement ont été sauvegardés et intégrés dans une application interactive développée avec **Streamlit**. Cette application permet d'utiliser le modèle pour prédire le risque de churn de nouveaux clients.

Ainsi, ce projet montre l'intérêt du Machine Learning pour mieux comprendre le comportement des clients et contribuer à l'identification des clients susceptibles de quitter l'entreprise.